

Nous utilisons l'approche bayésienne pour effectuer une prédiction sur la série temporelle *AirPassenger*. Nous utilisons le package **bsts**.

$$y_t = \mu_t + \tau_t$$
$$\mu_{t+1} = \mu_t + \eta_t$$

Nous effectuons 1000 simulations MCMC avec l'année 1960 comme année de validation. On ne considère pas les 100 premières simulations qui correspondent au temps de convergence de la chaîne de Monté-Carlo.

```
library(lubridate)
library(bsts)
library(dplyr)
library(ggplot2)
library(Boom)

data("AirPassengers")
Y <- window(AirPassengers, start=c(1949, 1), end=c(1959,12))
y <- log10(Y)

# ajout d'une marche aléatoire au modèle  $\mu_t = \mu_{t-1} + N(0, \sigma^2)$ 
ss <- AddLocalLevel(list(), y)
# ajout d'une composante stationnaire annuelle au modèle
ss <- AddSeasonal(ss, y, nseasons = 12)

bsts.model <- bsts(y, state.specification = ss, niter = 1000, ping=0, seed=2016)
```

Nous pouvons regarder les paramètres par défaut des distributions à priori.

```
bsts.model$prior

## $prior.guess
## [1] 0.1807634
##
## $prior.df
## [1] 0.01
##
## $initial.value
## [1] 0.1807634
##
## $fixed
## [1] FALSE
##
## $upper.limit
## [1] 0.2169161
##
## attr("class")
## [1] "SdPrior"          "DiffDoubleModel" "DoubleModel"     "Prior"

help(SdPrior)
# paramètres pour la loi Gamma inverse:
# prior.guess estimation deviation standard SdPrior
# df degree of freedom (df) pour calculer le  $R^2$  à priori
# upper.limit limite haute pour l'écart-type des résidus
# initial.value : valeur initiale de la chronique
# fixed : si sigma est fixé
```

```

### Get a suggested number of burn-ins
burn <- SuggestBurn(0.1, bsts.model)

### Predict
p <- predict.bsts(bsts.model, horizon = 12, burn = burn, quantiles = c(.025, .975))

### Actual versus predicted
d2 <- data.frame(
  # fitted values and predictions
  c(10^as.numeric(-colMeans(bsts.model$one.step.prediction.errors[-(1:burn),])+y),
    10^as.numeric(p$mean)),
  # actual data and dates
  as.numeric(AirPassengers),
  as.Date(time(AirPassengers)))
names(d2) <- c("Fitted", "Actual", "Date")

### 95% forecast credible interval
posterior.interval <- cbind.data.frame(
  10^as.numeric(p$interval[1,]),
  10^as.numeric(p$interval[2,]),
  subset(d2, year(Date)>1959)$Date)
names(posterior.interval) <- c("LL", "UL", "Date")
d3 <- left_join(d2, posterior.interval, by="Date")

### MAPE
MAPE <- filter(d2, year(Date)>1959) %>% summarise(MAPE=mean(abs(Actual-Fitted)/Actual))
MAPE


```

```


##           MAPE
## 1 0.06530951

```

Les prédictions du modèle pour les valeurs un temps en avant :

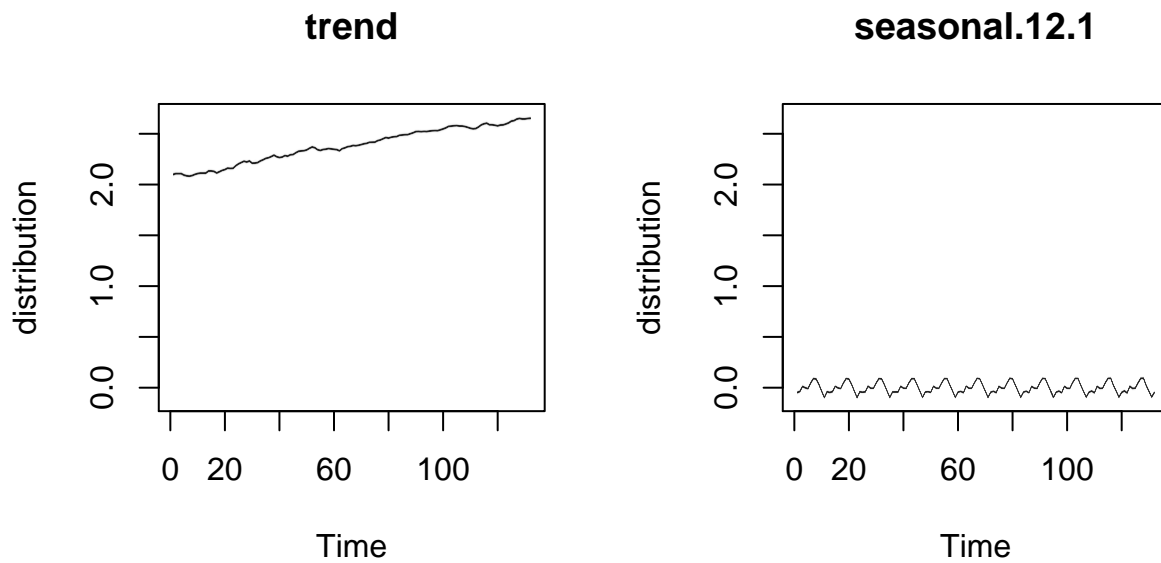


La prédiction du modèle pour l'année 1960:




Nous pouvons extraire du modèle la partie saisonnière et la tendance.

```
plot(bsts.model, "components")
```



Nous pouvons regarder l'évolution des valeurs échantillonnées pour des paramètres afin d'évaluer la convergence de la simulation.


```
plot(bsts.model$sigma.obs, type='l')
```




Cela justifie de prendre un burn-in de 10% des tirages, soit 100 tirages.

Nous pouvons également nous intéresser aux résidus du modèle et vérifier qu'ils correspondent bien à un bruit blanc

```
# affichage de la distribution à postérieure des résidus du modèle
PlotBstsResiduals(bsts.model, burn = SuggestBurn(0.1, bsts.model), style = "dynamic" )
```




Histogramme de la distribution postérieure des résidus



On affiche le corrélogramme de la distribution postérieure des résidus avec des boîtes à moustache pour chaque lag.


```
# qqline(r)  
AcfDist(r)
```



Pour finir nous pouvons observer les autocorrélations entre les étapes successives de l'échantillonneur pour une variable.

```
acf(bsts.model$sigma.obs,lag.max=50)
```


Series bsts.model\$sigma.obs



L'erreur relative de prédiction est plus importante au final pour l'approche bayésienne pour cette chronique ce qui nous fait dire que pour cette chronique, l'approche bayésienne est moins efficace.

Néanmoins si on compare les intervalles de confiance des prediction à 95% entre les deux approches pour une préition à long terme, nous pouvoir voir que l'intervale de confiance pour l'approche fréquentiste diverge beaucoup plus que celui correspondant à l'approche bayésienne.

Intervalle de confiance de la prediction pour l'approche bayésienne



Intervalle de confiance de la prediction pour l'approche fréquentiste

