


chronique AirPassenger du package TSA



L'affichage brut de la chronique indique un modèle multiplicatif avec une tendance, ce qui nous pousse à prendre le logarithme de la série pour avoir un modèle additif, et de la dériver pour ôter la tendance linéaire pour la modélisation.

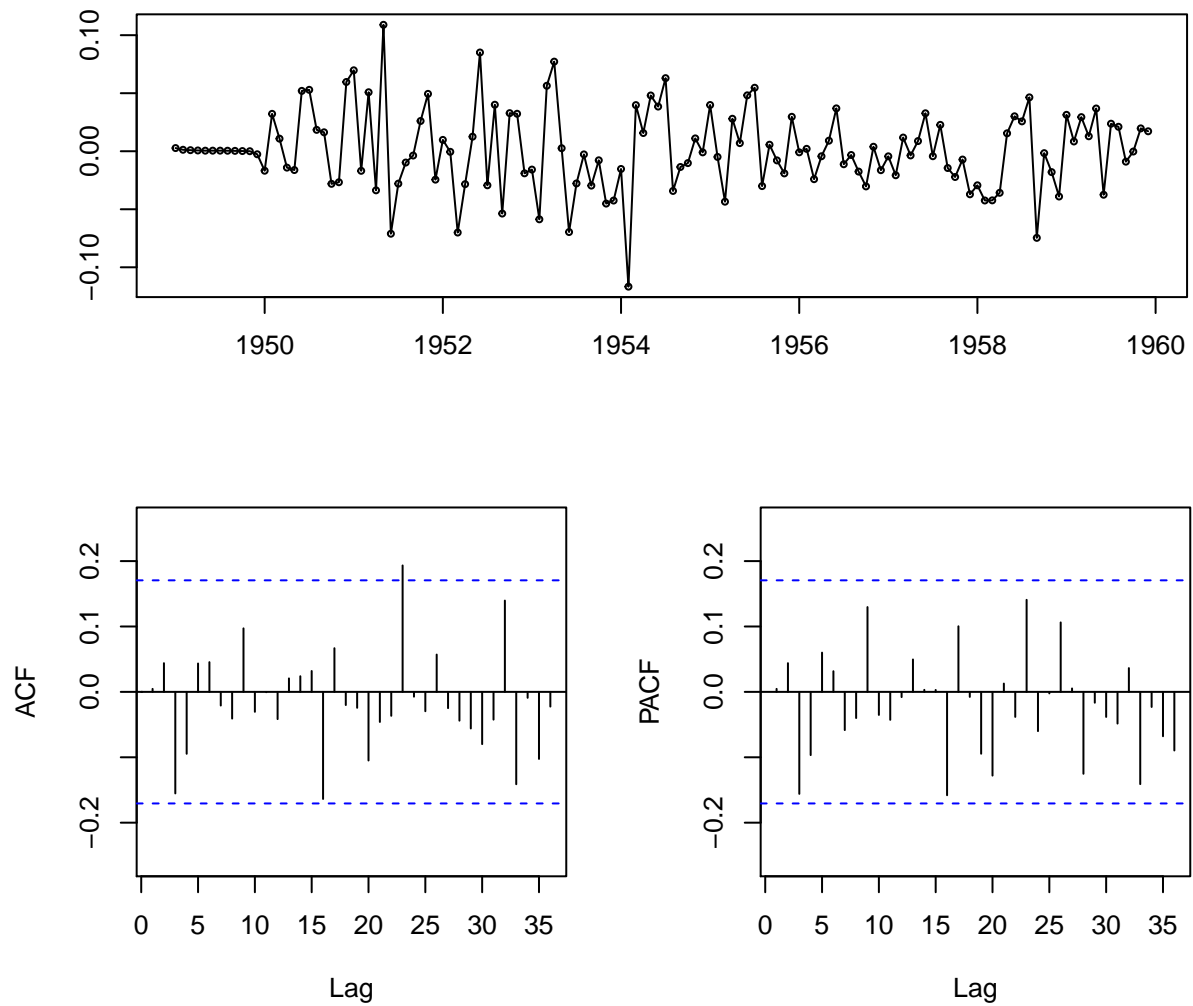
On modélise le logarithme de la chronique avec un processus SARIMA[0, 1, 1][0, 1, 1]₁₂

```
AP <- window(AirPassengers, start=c(1949, 1), end=c(1959, 12))
#tsdisplay(AirPassengers)
analyse = Arima(AP, lambda = 0, order = c(0, 1, 1), seasonal = c(0, 1, 1))
```

Pour valider le modèle nous vérifions que les résidus sont des bruits blanc gaussiens. On regarde tout d'abord si on trouve des structures significatives dans les résidus, ce qui n'est pas le cas ici.

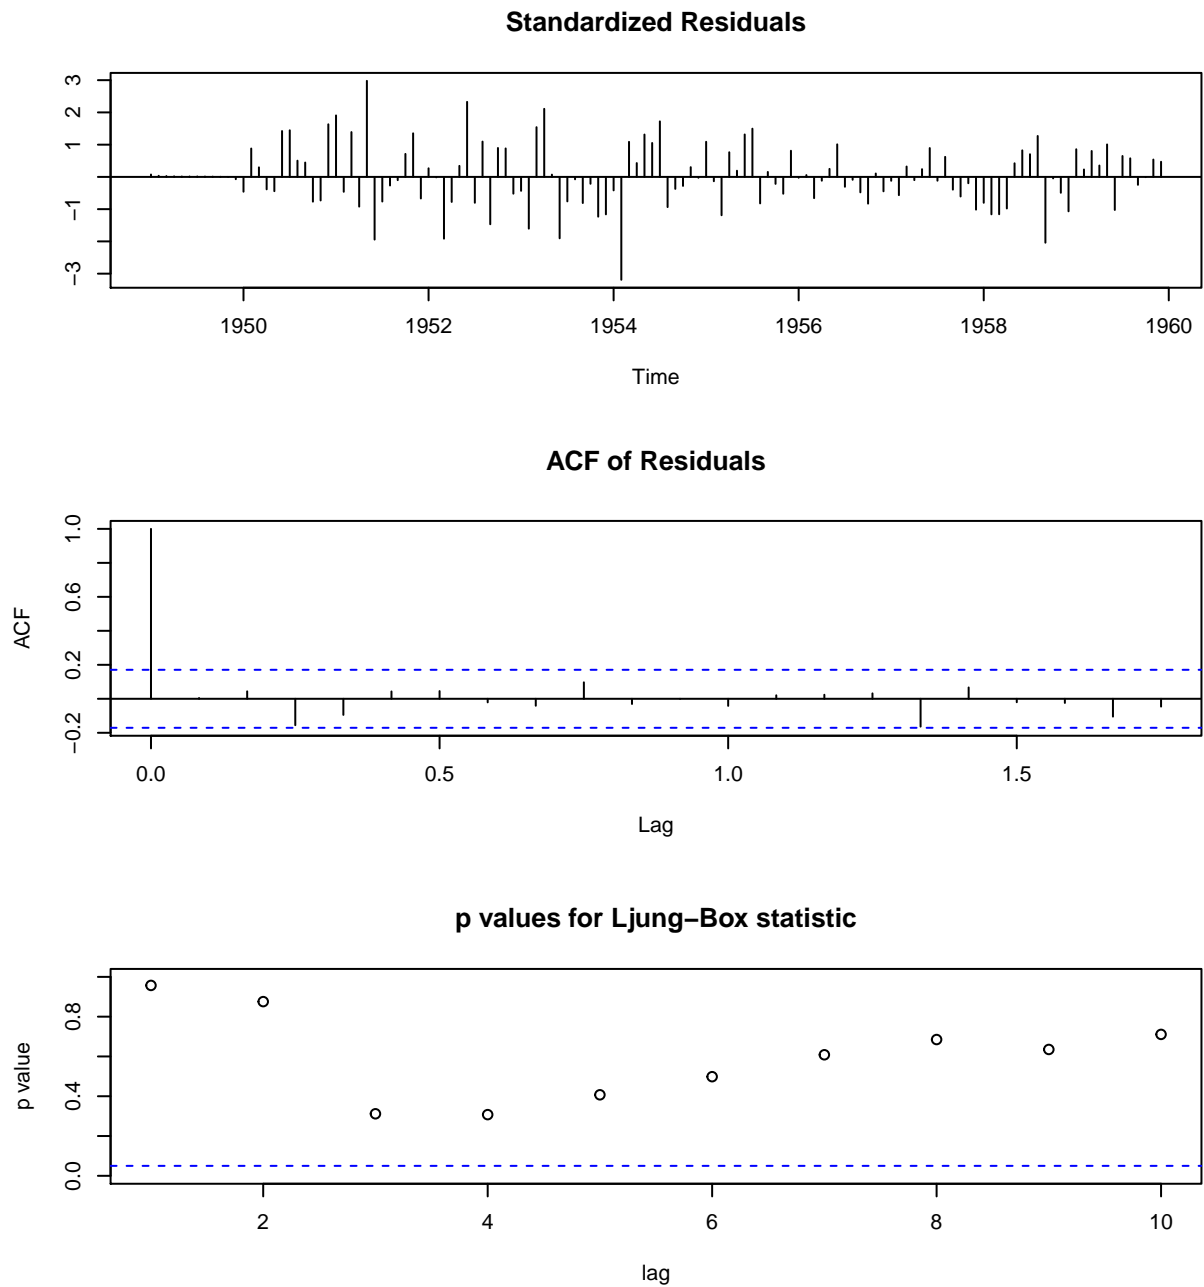
```
tsdisplay(residuals(analyse))
```

residuals(analyse)



On effectue ensuite un test du porte-manteau (Ljung-Box). On vérifie que les p-values sont bien supérieures au seuil 5%.


```
tsdiag(analyse)
```



On peut également regarder la droite de Henry pour vérifier le caractère gaussien des résidus. Si les résidus sont parfaitement gaussiens ils collent à la droite de Henry.

```
qqnorm(residuals(analyse))  
qqline(residuals(analyse))
```

Normal Q-Q Plot



On peut ensuite vérifier la significativité des coefficients du modèle par un test de Wald sous l'hypothèse H_0 que les coefficients sont nuls.

```
coeftest(analyse)
```

```
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ma1  -0.348448   0.094280 -3.6959 0.0002191 ***
## sma1 -0.562260   0.077416 -7.2629 3.79e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

On peut finalement afficher l'estimation des coefficients du modèle avec les critères AIC et BIC ainsi que les pondérateurs pour mesurer l'erreur.

```
summary(analyse)
```

```
## Series: AP
## ARIMA(0,1,1)(0,1,1)[12]
## Box Cox transformation: lambda= 0
##
## Coefficients:
##      ma1      sma1
##    -0.3484  -0.5623
## s.e.   0.0943   0.0774
##
## sigma^2 estimated as 0.001338:  log likelihood=223.63
## AIC=-441.26   AICc=-441.05   BIC=-432.92
##
```

```
## Training set error measures:
##           ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.2583509 9.000802 6.753838 0.04571618 2.58749 0.2218009
##           ACF1
## Training set 0.02125945
```


On peut finalement afficher la prédiction pour l'année suivante avec l'intervalle de confiance à 95%:

```
pred = forecast(analyse, h=12, level=0.95, lambda = 0)
```

```
## Warning in InvBoxCox(pred$pred, lambda, biasadj, var(residuals.Arima(object)), :
## biasadj information not found, defaulting to FALSE.
```

```
plot(pred)
```

Forecasts from ARIMA(0,1,1)(0,1,1)[12]



Pour mesurer l'erreur de prédiction on utilise le pourcentage d'erreur relative MAPE

$$\text{MAPE} = \frac{100}{T} \sum_{t=1}^T \left| \frac{X_t - \hat{X}_{t-1}}{X_t} \right| \text{ avec } \hat{X}_t \text{ la prediction de } X_t \text{ à partir de } X_{t-1}$$

```
Y_true <- window(AirPassengers, start=c(1960, 1))
MAPE <- mean(abs(Y_true - pred$mean)/Y_true)
MAPE
```

```
## [1] 0.02904473
```